

# Modelos para la Media Condicional Univariados.

December 5, 2022

# Contenido

---

- Series Financieras.
- Modelos Univariados (ARMA).

# Series de tiempo Económicas y Financieras

---

- Datos Económicos:
  - baja frecuencia (PIB)
  - ciclos, tendencias.
- Datos Financieros:
  - mediana y alta frecuencia.
  - Media condicional:
  - Varianza medición y pronóstico:

# Media Condicional

---

- observables.
- precios a retornos.
- retornos diarios  $E[r_t] = 0$ .
- dependencia intertemporal.
- estacionarios, memoria larga o corta.
- heteroscedasticidad.
- Colas pesadas (no-normalidad).
- no-predecible (AOA).
- microestructura de los mercados (ruido).

# Formalización de los datos

---

- $Y$  variable aleatoria (rv)
- $y$  realización de rv.
- $Y$  generado por modelo estadístico  $(\Omega, \mathcal{Y}, \mathcal{P})$ .
- $Y$  tiene proceso generador de datos (DGP).
- $Y_{\cdot}$  proceso estocástico (rv indexada).
- $Y_t$  serie de tiempo (rv indexada por el tiempo).
- Dependencia a través del tiempo.
- No necesariamente predecible.

# El muestreo de los datos

---

- Frecuencia: trimestre, mes, día, intradía.
- rv continuas y discretas (distribuciones).
- Los datos son discretos!

En estadística mas datos  $\{y_t\}_{t=0}^T$  es mejor.

- Baja frecuencia (clásico).
  - $\Delta$  fijo  $n \rightarrow \infty$ .
  - índice  $t \in (0, T := \frac{n}{\Delta})$ .
  - Estacionariedad y ergodicidad es importante.
- Alta frecuencia en 1 día.
  - $\Delta = \Delta_n \rightarrow 0$  cuando  $n \rightarrow \infty$ .
  - índice  $t \in (0, T := \frac{1}{\Delta_n})$ .
  - ergodicidad es importante.
- Mixto  $\Delta_n \rightarrow 0$  y varios días.

# Proceso generador de datos: difusión

---

Proceso de precios  $S_t = S_0 \exp(X_t)$   
en tiempo continuo donde  $X_t$

$$X_t = X_0 + \int_0^t b ds + \int_0^t \sigma dW_s$$

donde  $W$  movimiento Browniano.

$S_t$  es proceso Browniano geométrico  
con retorno instantaneo.

$$\frac{\partial S_t}{S_t} = b dt + \sigma dW_t$$

Discretizado,

$$r_{t+1} := \ln S_{t+1} - \ln S_t = (b - \frac{\sigma^2}{2})(t+1-t) + \sigma \sqrt{t+1-t} Z_{t+1}$$

con  $Z_{t+1} \sim N(0, 1)$

# Proceso de Levy, mas general

---

$$X_t = bt + \sigma W_t + (x \mathbf{1}_{\|x\| \leq \varepsilon}) * (\mu - \nu)_t + (x \mathbf{1}_{\|x\| > \varepsilon}) * \mu_t$$

donde  $W$  movimiento Browniano y  $\mu$  medida de Poisson.

Descomposición canónica:


- drift (tendencia)
- continuous martingale (difusión)
- purely discontinuous martingale (saltos "pequeños"  $< \varepsilon$ ).
- purely discontinuous martingale (saltos "grandes"  $> \varepsilon$ ).

$$X_t = bt + \sigma W_t + \sum_{s \leq t} \Delta X_s \mathbf{1}_{\|x\| > \varepsilon}$$



# variación continua vs saltos

---



# Análisis de series de tiempo

---

- Objetivo pronóstico:  $E[y_{t+h} \mid \mathcal{F}_t]$
- Cual es la forma "funcional" de la media condicional?
- La función sera lineal utilizando proyección ortogonal.
- Descomponer los datos

## Descomposición clásica

- determinístico  $v_t$  (finanzas no muy importante)
  - tendencia.
  - ciclo.
- estocástico
  - regular (estacionario): Descomposición de Wold.
  - irregular (ruido).

# Estacionariedad

---

## Estacionariedad estricta:

$y_t$  es estacionario  $\Leftrightarrow \forall t_1 < t_2 < \dots < t_k$

su distribución conjunta:

$$L(y_{t_1}, y_{t_2}, \dots, y_{t_k}) \propto L(y_{t_1+h}, y_{t_2+h}, \dots, y_{t_k+h})$$

desplazamiento en el tiempo no afecta su DGP.

## Estacionariedad débil:

$y_t$  es débilmente estacionario (momentos no-condicionales):

- $E[y_t]$  independiente  $t$ .
- $Var[y_t]$  finito, positivo, independiente  $t$ .
- $Cov[y_t, y_s]$  función finita de  $t - s$ .

La relación entre dos variables con índices de tiempo diferente no depende del índice, solo de la distancia (temporal entre ellas).

Proporciona principio de intercambiabilidad (inferencia).

# Estacionariedad en proceso autoregresivo

---

Considere AR(1)

$$y_t = \mu + \rho y_{t-1} + \epsilon_t$$

donde  $\epsilon_t$ :

- $E[\epsilon_t] = 0$ .
- $Var[\epsilon_t] = \sigma^2 \forall t$

Comportamiento del proceso AR(1)

- $|\rho| = 1$  no estacionario.
- $\rho \in (-1, 1)$  estacionario.
- $|\rho| > 1$  explosivo.

# Estacionariedad en proceso autoregresivo

---

recursión AR(1):

$$y_t = \mu + \rho y_{t-1} + \epsilon_t$$

$$y_{t-1} = \mu + \rho y_{t-2} + \epsilon_{t-1}$$

.

.

$$y_{t-k} = \mu + \rho y_{t-k-1} + \epsilon_{t-k}$$

el resultado es descomposición de Wold ( $y_t = \sum_{j=0}^{\infty} \psi_j \epsilon_{t-j} + v_t$ )

$$y_t = \mu(1 + \rho + \rho^2 + \dots + \rho^k) + \rho^k y_{-0} + \epsilon_t + \rho \epsilon_{t-1} + \rho^2 \epsilon_{t-2} + \dots + \rho^k \epsilon_{t-k}$$

$$y_t = \mu \sum_{i=0}^k \rho^i + \rho^k y_{-0} + \sum_{i=0}^k \rho^i \epsilon_{t-i}$$

Valor de  $\rho$  determina comportamiento.

# Ergodicidad

---

Ergodicidad es versión de LLN en análisis de series de tiempo

## **Ergodicity:**

Sea  $\{Y_t\}$ ,  $t = 1, \dots, T$  proceso estacionario ergódico,  
entonces  $E | Y_t | < \infty \Rightarrow \bar{Y}_n \rightarrow_{a.s.} \mu \equiv E[Y_t]$ .

- $\{Y_t\}$  realización tamaño  $T$  del proceso.
- Autocovarianza acotada (va a cero en la medida en que  $j$  incrementa)  
 $\sum_{j=0}^{\infty} |\gamma_j| < \infty$  entonces  $\{Y_t\}$  es ergódico en la media.

# Proceso autoregresivo de orden superior AR(p)

---

AR(P)

$$y_t = \rho_1 y_{t-1} + \rho_2 y_{t-2} + \dots + \rho_p y_{t-p} + \epsilon_t$$

Estacionariedad de AR(p)

$$y_t = \gamma_1 y_{t-1} + \gamma_2 y_{t-2} + \dots + \gamma_p y_{t-p}$$

$$y_t = (\gamma_1 L + \gamma_2 L^2 + \dots + \gamma_p L^p) y_t$$

$L$  operador de rezago  $y_t L = y_{t-1}$

Ecuación característica:

$$C(z) = 1 - \gamma_1 z - \gamma_2 z^2 - \dots - \gamma_p z^p$$

raíces (ceros) por fuera del círculo unitario.

# Media Movil MA(q)

---

Decomposición de Wold

$$y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$$

truncando numero  $q$  parámetros

$$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

donde  $\varepsilon_t \sim WN(0, \sigma^2)$



# Modelo autoregresivo y media móvil ARMA(p,q)

---

$\{y_t\}$  es ARMA(p,q)

$$y_t - \phi_1 y_{t-1} - \dots - \phi_p y_{t-p} = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

polinomio ARMA(p,q),

$$\Phi(L)y_t = \Theta(L)\varepsilon_t$$

con  $\Phi(L) = 1 - \sum_{i=1}^p \phi_i L^i$  y  $\Theta(L) = 1 - \sum_{i=1}^q \theta_i L^i$

# Como determinar (p,q)?

---

- Descomposición de Wold
  - Filtro genera ruido blanco.

$$\frac{\Phi(L)}{\Theta(L)}y_t = \varepsilon_t$$

$$\Psi(L)y_t = \varepsilon_t$$

- Metodo de Box-Jenking
  1. Identificación (ACF, PACF)
  2. Estimación
  3. Diagnostico
- Automatización
  - Auto-arima
  - Criterios Información

# Función de autocorrelacion (ACF)

---

Autocovarianza

$$\lambda_k = \text{Cov}[y_t, y_{t-k}]$$

Autocorrelación  $\lambda_0$ , varianza

$$\hat{\rho}_k = \frac{\lambda_k}{\lambda_0}, \quad -1 \leq \rho_k \leq 1$$

- correlación bruta entre  $y_t$  y  $y_{t-k}$ .
- dependencia intertemporal.
- función decae en procesos estacionarios.
- decae menor ritmo, procesos larga memoria.

# ACF, AR(1)

---

$$y_t = \gamma y_{t-1} + e_t$$

Autocovarianza

$$\begin{aligned} \text{Cov}(y_t, y_{t+k}) &= E[y_t y_{t+k}] = E[y_t(\gamma y_{t+k-1} + e_{t+k})] \\ &= \gamma E[y_t y_{t+k-1}] + E[y_t e_{t+k}] \\ &= \gamma E[y_t(\gamma y_{t+k-2} + e_{t+k-1})] \\ &= \gamma^2 E[y_t y_{t+k-2}] + E[y_t e_{t+k-1}] \\ &\quad \cdot \\ &\quad \cdot \\ &= \gamma^k E[y_t y_t] \\ &= \gamma^k \lambda_0 \end{aligned}$$

# ACF, AR(1)

---

## Autocorrelación

$$\rho_k = \gamma^k$$

- serie geometrica.
- $\rho_0 = 1$
- decae monotónicamente  $0 < \gamma < 1$
- cambio signos  $-1 < \gamma < 0$

# ACF MA(1)

---

$$y_t = e_t - \theta e_{t-1}$$

Autocovarianza

$$\lambda_0 = (1 + \theta^2)\sigma_e^2$$

$$\lambda_1 = -\theta\sigma_e^2$$

Autocorrelación

$$\rho_k = \frac{-\theta}{(1 + \theta^2)}$$

No depende de  $k$  trunca en  $k = 1$ .

# Autocorrelación parcial PACF

---

Medir correlación neta entre  $y_t$

y  $y_{t-2}$  eliminar efecto de  $y_{t-1}$ .

Función de autocorrelación parcial:

$$\rho_k^* = \text{Corr}(y_t - E^*(y_t | y_{t-1}, \dots, y_{t-k+1}), y_{t-k}),$$

donde

$$E^*(y_t | y_{t-1}, \dots, y_{t-k+1}) = \min_{\phi} E[(y_t - \phi_1 y_{t-1} + \dots + \phi_{k+1} y_{t-k+1})^2]$$

Minimizar error/proyección ortogonal

# Identificación Box-Jenkins

---

A partir de DGP

	ACF	PACF
AR(p)	$\downarrow$ Monotonically $\mapsto p$	Truncated $\mapsto p$
MA(q)	Truncated $\mapsto p$	$\downarrow$ Monotonically $\mapsto p$
ARMA(p,q)	$\downarrow$ Monotonically $\mapsto p$	$\downarrow$ Monotonically $\mapsto p$



# Método Box-Jenkins

---

1. Test de Raíz Unitaria (ADF, KPSS).
2. Garantizar estacionariedad (retornos).
3. Identificación
  - gráfica (ACF, PACF)
  - automatizada AutoArima
4. Estimación.
5. Diagnostico: error estimado es ruido blanco?.
  - No, regresar a 2.
  - Si, proceder 5.
6. Pronóstico.

# Estimación Máxima Verosimilitud

---

ARMA(p,q), dado valores  $p$  y  $q$ .

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

$\varepsilon_t \sim i.i.d.N(0, \sigma^2)$ ,  $\delta = (\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q)$ .

Si  $\varepsilon_t$  Gaussiana  $\Rightarrow$  Máxima Verosimilitud.

Si  $\varepsilon_t$  no Gaussiana  $\Rightarrow$  Quasi-Máxima Verosimilitud.

# Máxima Verosimilitud, Gaussiana

---

Sea  $\varepsilon_t \sim N(0, \sigma^2)$ .

$$L_{\delta, \sigma^2}(\mathbf{y}) = \left(\frac{1}{2\pi}\right)^{n/2} \frac{1}{(\Sigma(\delta, \sigma^2))^{n/2}} \exp\left\{-\frac{1}{2}\mathbf{y}'(\Sigma(\delta, \sigma^2))^{-1}\mathbf{y}\right\}$$

Estimación de parámetros

$$\hat{\delta}_{ML} = \operatorname{argmin}_{\delta \in \mathcal{T}} \ln(L(\delta)) = \operatorname{argmin}_{\delta \in \mathcal{T}} \frac{1}{n} \mathbf{y}'(M(\delta))^{-1}\mathbf{y} \mid M(\delta) \mid^{1/n}$$

$$\hat{\sigma}_{ML} = \mathbf{y}'(M(\hat{\delta}_{ML}))^{-1}\mathbf{y}$$

Concentración de la función de verosimilitud:  $\ln(L(\delta, \sigma(\delta)))$

# Criterios de Información

---

Tamaño ARMA(p,q): trade-off ajuste dentro de la muestra y flexibilidad.

- Akaike:  $AIC_{p,q} = -2 \ln L_{\hat{\delta}, \hat{\sigma}^2; \text{Gaussian}} + 2(p + q + 1)$ , sobrestima (p,q)
- $AIC_{p,q} = -2 \ln L_{\hat{\delta}, \hat{\sigma}^2; \text{Gaussian}} + \frac{2(p+q+1)T}{T-p-q-2}$ , alta penalidad, para  $AR(p)$  eficiente  $T \rightarrow \infty$
- Bayesian  $BIC_{p,q} = (T - p - q) \ln \frac{\hat{\sigma}^2}{T-p-q} + (p + q) \ln \frac{(\sum_{i=1}^T y_i^2 - T\sigma^2)}{p+q}$  consistente para  $(p, q)$ ,  $T \rightarrow \infty$ .

Escoger ARMA(p,q) minimiza criterios

# Diagnostico

---

Modelo poblacional  $\Phi(L)y_t = \Theta(L)\varepsilon_t$ ,  $\varepsilon_t \sim i.i.d.N(0, \sigma^2)$ .  
Representación de Wold,

$$\varepsilon_t = \frac{\Theta(L)}{\Phi(L)}y_t = \Psi(L)y_t = \sum_{i=0}^{\infty} \psi_i y_{t-i}$$

Para unos valores (p,q) revisar  $\varepsilon_t \sim i.i.d.N(0, \sigma^2)$ :

- **Homoscedastisidad.**
- Distribución Normal.

# Homoscedasticidad error

---

- Test Portmanteau, Rechazar  $H_0 : \varepsilon_t \sim N(0, \sigma^2) \Leftrightarrow T \sum_{k=1}^h (\hat{\rho}_{\hat{\varepsilon}}(k))^2 > \lambda_{h-p-q, 1-\alpha}^2$
- Mejorar desempeño en muestra finita.
- Test Q (Ljung-Box)  $T \sum_{k=1}^h \frac{T+2}{T-k} (\hat{\rho}_{\hat{\varepsilon}}(k))^2 > \lambda_{h-p-q, 1-\alpha}^2$

# Pronostico

---

Pronostico 1 periodo adelante  $y_{t+1|t}$  de  $y_t$  información en  $t$ .

Mean square error: Función de perdida (cuadrática)

$$MSE(y_{t+1|t}) = E(y_{t+1} - y_{t+1|t})^2$$

Métricas

- RMSE  $\sqrt{\frac{1}{T} \sum_{i=t_1}^T (y_{i+1} - y_{i+1|i})^2}$
- MAE  $\frac{1}{T} \sum_{i=t_1}^T |y_{i+1} - y_{i+1|i}|$

# Combinación de pronósticos, Newbold and Granger, 1974

---

Sea  $f_{1,t+s|t}$  y  $f_{2,t+s|t}$  pronósticos de  $y_{t+s}$  con información en  $t$ . Si pronósticos son insesgados,  $E(e_{i,t+s}) = 0$  para  $i = 1, 2$ , donde  $e_{i,t+s} = y_{t+s} - f_{i,t+s|t}$  y  $\sigma_i^2$  es error de pronóstico y la varianza.

Pronóstico combinado,

$$f_{c,t+s|t} = (1 - \lambda)f_{1,t+s|t} + \lambda f_{2,t+s|t}$$

$\lambda \in [0, 1]$ . Error pronóstico combinado

$$e_{c,t+s} = y_{t+s} - f_{c,t+s|t} = (1 - \lambda)e_{1,t+s} + \lambda e_{2,t+s}$$

$E(e_{c,t+s}) = 0$ , y varianza

$$E(e_{c,t+s}^2) = (1 - \lambda)^2 \sigma_1^2 + \lambda^2 \sigma_2^2 + 2\lambda(1 - \lambda)\rho\sigma_1\sigma_2$$



# Combinación de pronósticos

---

$E(e_{c,t+s}^2)$  se minimiza si  $\lambda$

$$\lambda_{opt} = \frac{\sigma_1^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 + 2\rho\sigma_1\sigma_2}$$

$(\sigma_1^2, \sigma_2^2, \rho)$  no observado, pero podemos tener el desempeño histórico de modelos  $(e_{1,t}, e_{2,t})$ ,  $t = 1, \dots, T$ , calcular equivalente muestral.

$$\hat{\lambda}_{opt} = \frac{\sum_{t=1}^T e_{1,t}^2 - \sum_{t=1}^T e_{1,t}e_{2,t}}{\sum_{t=1}^T e_{1,t}^2 + \sum_{t=1}^T e_{2,t}^2 - 2\sum_{t=1}^T e_{1,t}e_{2,t}}$$

# Test comparación desempeño pronostico, Morgan-Granger-Newbold

---

- observados  $y_t, t = 1, \dots, T$
- pronósticos  $\tilde{y}_{1,t}, \tilde{y}_{2,t} \quad t = 1, \dots, T$
- errores pronostico  $e_{i,t} = \tilde{y}_{i,t} - y_t$
- perdida por pronostico  $g(y_t, \tilde{y}_{i,t}) = g(\tilde{y}_{i,t} - y_t) = g(e_{i,t})$
- comparación desempeño  $d_t = g(e_{1,t}) - g(e_{2,t})$

Hipótesis de igual desempeño  $H_0 : E(d_t) = 0 \quad \forall t, H_a : E(d_t) = \mu, \mu \neq 0$

Supuestos del test,

1. función de perdida cuadrática.
2. pronostico 1 periodo adelante.
3. errores pronostico  $e_{i,t} \sim N(0, \sigma_i^2)$ .

# Test comparación desempeño pronóstico, Morgan-Granger-Newbold

---

bajo los anteriores supuestos determinamos ortogonalidad entre los errores,

$$x_t = e_{1,t} + e_{2,t}$$

$$z_t = e_{1,t} - e_{2,t}$$

$$\Rightarrow \text{Cov}(x_t, z_t) = E(e_{1,t}^2 - e_{2,t}^2)$$

Estadístico

$$MGN = \frac{r}{((1 - r^2)/(T - 1))^{1/2}}$$

donde  $r = \frac{x'z}{((x'x)(z'z))^{1/2}}$ , bajo la nula  $MGN \sim \text{student} - t_{T-1}$

# Test comparación desempeño pronostico, Diebold-Mariano

---

Test mas flexible (no sujeto a supuestos).

Calcular proceso desempeño diferenciado  $\{d_i\}_{i=1}^T$ , si proceso es débilmente estacionario.

$$\sqrt{T}(\bar{d} - \mu) \rightarrow N(0, 2\pi f_d(0))$$

donde  $\bar{d}$  diferencia muestral promedio y  $f_d(\cdot)$  densidad espectral

$$f_d(\lambda) = \frac{1}{2\pi} \sum_{k=-\infty}^{\infty} \gamma_d(k) \exp(-ik\lambda), -\pi \leq \lambda \leq \pi$$

$$\bar{d} = \sum_{t=1}^T \frac{(g(e_{1,t}) - g(e_{2,t}))}{T}$$

# Test comparación desempeño pronóstico, Diebold-Mariano

---

Estadístico

$$DM = \frac{\bar{d}}{(2\pi\hat{f}_d(0)/T)^{1/2}}$$

Rechaza  $H_0 : E(d_t) = 0$  si  $|DM| > Q_{N(0,1), 1-\alpha}$ ,  
 $\hat{f}_d(0)$  estimada de manera no-paramétrica.